Detecting Silent Failures of Uncertainty Estimators in Large Language Models under Distribution Shift

تشخیص شکست‌های پنهان تخمین‌گرهای عدم‌قطعیت در مدل‌های زبانی بزرگ تحت تغییر توزیع داده‌ها

استاد :دکتر راحیل حسینی

دانشگاه آزاد اسلامی واحد تهران شمال

گردآوری‌شده توسط :محمد مهدی نصرتی

شرح مسئله

مدل‌های زبانی بزرگ (LLMs) با وجود توانایی بالا در پاسخ‌گویی به پرسش‌های مختلف، گاهی پاسخ‌های نادرست را با اطمینان بالا تولید می‌کنند. برای ارزیابی میزان اطمینان‌پذیری این پاسخ‌ها، از روش‌های تخمین عدم‌قطعیت (Uncertainty Estimation) استفاده می‌شود؛ بااین‌حال، این روش‌ها نیز همیشه قادر به شناسایی پاسخ‌های نادرست نیستند و ممکن است برخی از این پاسخ‌ها را به‌اشتباه قابل‌اعتماد ارزیابی کنند. این چالش می‌تواند در شرایط تغییر توزیع داده‌ها(Distribution Shift) ، یعنی زمانی که مدل با پرسش‌هایی متفاوت از داده‌های مورد ارزیابی قبلی مواجه می‌شود، اهمیت بیشتری پیدا کند. در این پژوهش، تمرکز بر بررسی این نوع شکست پنهان (Silent Failure) است؛ وضعیتی که در آن پاسخ مدل نادرست است، اما تخمین‌گر عدم‌قطعیت قادر به شناسایی قابل‌اعتماد نبودن آن نیست. هدف، بررسی وقوع این شکست‌ها در مجموعه‌داده‌های مختلف و ارزیابی تأثیر تغییر توزیع داده‌ها بر توانایی روش‌های تخمین عدم‌قطعیت در شناسایی پاسخ‌های نادرست است.

دیتاست

در این پروژه از مجموعه‌داده‌های انگلیسیِ چندگزینه‌ای استفاده می‌شود .این داده‌ها سؤال، گزینه‌های پاسخ و کلید پاسخ صحیح دارند؛ بنابراین می‌توان درستی پاسخ .مدل را با برچسب مرجع مقایسه کرد .در ادامه، ساختار هر مجموعه، تعداد نمونه‌ها و معنای فیلدهای اصلی معرفی می‌شود

مجموعه پرسش‌های دانش عمومی :CommonsenseQA

شامل ۱۲٬۱۰۲ سؤال چندگزینه‌ای است که به دانش عمومی و استدلال روزمره نیاز دارند .هر سؤال پنج گزینه دارد :یک پاسخ صحیح و چهار CommonsenseQA نیز مفهوم مرتبط با سؤال را مشخص می‌کند .این مجموعه برای مطالعه خطاهای مدل در پرسش‌های عمومی مناسب question_concept گزینه انحرافی .فیلد .است

جدول)۱ :(نمای کلی بخش‌های دیتاست

بخش داده (Split)	تعداد نمونه	توضیح
Train	۹,۷۴۱	بخش آموزش؛ شامل سؤال، گزینه‌ها و کلید پاسخ
Validation	۱,۲۲۱	بخش اعتبارسنجی برای ارزیابی
Test	۱,۱۴۰	بخش آزمون نهایی
مجموع	۱۲,۱۰۲	مجموع نمونه‌های نسخه معرفی‌شده

CommonsenseQA ساختار فیلدهای دیتاست

جدول ۲) :فیلدهای اصلی هر نمونه

فیلد (Field)	نوع داده	توضیح
id	رشته (String)	شناسه یکتای هر سؤال
question	رشته (String)	متن سؤال
question_concept	رشته (String)	مفهوم یا کلیدواژه مرتبط با سؤال
choices.label	فهرست برچسب‌ها	برچسب گزینه‌ها، معمولاً A تا E
choices.text	فهرست متن‌ها	متن هر یک از پنج گزینه پاسخ
answerKey	رشته (String)	برچسب گزینه صحیح؛ برای مثال A یا C

ARC-Challenge

بر پرسش‌هایی تمرکز دارد ARC-Challenge مجموعه‌ای از پرسش‌های علمی چندگزینه‌ای در سطح مدرسه است .نسخه (AI۲ Reasoning Challenge) ARC که برای روش‌های ساده‌تر بازیابی اطلاعات و هم‌وقوعی واژه‌ها دشوار بوده‌اند .این ویژگی آن را برای بررسی عملکرد مدل در پرسش‌های علمی و مقایسه با سؤالات دانش .عمومی مناسب می‌کند

ARC-Challenge جدول ۳) :تعداد نمونه‌های

بخش داده	تعداد نمونه	توضیح
Train	۱,۱۱۹	نمونه‌های آموزش
Validation	۲۹۹	نمونه‌های اعتبارسنجی
Test	۱,۱۷۲	نمونه‌های آزمون
مجموع	۲,۵۹۰	ARC-Challenge مجموع

ساختار فیلدهای دیتاست ARC-Challenge

جدول ۴) :فیلدهای اصلی

فیلد (Field)	نوع داده	توضیح
id	رشته (String)	شناسه نمونه سؤال
question	رشته (String)	متن پرسش علمی
choices.label	فهرست برچسب‌ها	برچسب گزینه‌ها، مانند A، B، C و D
choices.text	فهرست متن‌ها	متن گزینه‌های پاسخ
answerKey	رشته (String)	برچسب پاسخ صحیح

MMLU

مجموعه‌ای از پرسش‌های چندگزینه‌ای در ۵۷ حوزه موضوعی، از جمله ریاضیات، (Measuring Massive Multitask Language Understanding) MMLU تاریخ، حقوق، پزشکی، علوم طبیعی و علوم کامپیوتر است .این تنوع امکان بررسی عملکرد مدل در موضوعات عمومی و تخصصی را فراهم می‌کند .نسخه cais/mmlu .است auxiliary_train و ۹۹،۸۴۲ نمونه dev شامل ۱۴،۰۴۲ نمونه آزمون، ۱،۵۳۱ نمونه اعتبارسنجی، ۲۸۵ نمونه

cais/mmlu جدول ۵) :بخش‌های نسخه

بخش داده	تعداد نمونه	توضیح
Auxiliary train	۹۹,۸۴۲	داده آموزشی کمکی؛ شامل منابع متنوع پرسش چندگزینه‌ای
Dev	۲۸۵	پنج نمونه برای هر زیرحوزه در تنظیمات few-shot
Validation	۱,۵۳۱	نمونه‌های اعتبارسنجی
Test	۱۴,۰۴۲	آزمون اصلی در حوزه‌های مختلف

MMLU جدول ۶) :فیلدهای اصلی

فیلد	نوع داده	توضیح
question	رشته	متن سؤال
subject	رشته	نام حوزه یا زیرموضوع سؤال
choices	فهرست چهار رشته	چهار گزینه پاسخ
answer	برچسب کلاسی	پاسخ صحیح؛ مقادیر ۰ تا ۳ متناظر با A تا D

TruthfulQA-MC

برای بررسی این طراحی شده است که آیا مدل‌های زبانی پاسخ‌های درست و حقیقت‌محور می‌دهند یا باورهای نادرست رایج را بازتولید می‌کنند .نسخه TruthfulQA شامل ۶۸۴ سؤال چندگزینه‌ای در حوزه‌هایی مانند سلامت، قانون، مالیه و سیاست است .این نسخه ساده‌شده فقط EleutherAI موجود در مخزن TruthfulQA-MC در مقاله ۸۱۷ سؤال دارد؛ عدد ۶۸۴ TruthfulQA سؤال‌هایی را نگه می‌دارد که دست‌کم چهار گزینه دارند و برای هر سؤال چهار گزینه انتخاب می‌کند .نسخه اصلی .مربوط به همین نسخه چندگزینه‌ای ساده‌شده است

TruthfulQA-MC جدول)۷ :(نمای کلی

بخش داده	تعداد نمونه	توضیح
Validation	۶۸۴	تنها بخش موجود در نسخه معرفی‌شده

TruthfulQA-MC جدول)۸ :(فیلدهای اصلی

فیلد	نوع داده	توضیح
question	رشته	سؤال طراحی‌شده برای سنجش حقیقت‌گویی
choices	فهرست چهار رشته	چهار گزینه پاسخ که یکی از آن‌ها به‌عنوان صحیح برچسب خورده است
label	عدد صحیح	؛ در پایتون از اندیس صفر شروع می‌شودchoices اندیس گزینه صحیح در فهرست

(Feature Vector) ویژگی‌های قابل استخراج و بردار ویژگی

فیلدهای اصلی دیتاست‌ها)مانند متن سؤال، گزینه‌ها و دسته موضوعی (به‌تنهایی بردار ویژگی نهایی نیستند .برای هر سؤال، می‌توان علاوه بر اطلاعات متنی، ویژگی‌هایی را از .توزیع احتمال گزینه‌های مدل و رفتار پاسخ‌گویی آن استخراج کرد .فهرست زیر یک نمایش کلی و اولیه است؛ انتخاب نهایی ویژگی‌ها به بررسی داده‌ها و نظر استاد وابسته است

جدول)۹ :(فهرست اولیه ویژگی‌های هر سؤال

ویژگی	توضیح
(p_max) بیشترین احتمال گزینه	بزرگ‌ترین احتمال پیش‌بینی‌شده بین گزینه‌ها؛ نشان می‌دهد مدل با چه شدتی از گزینه برتر حمایت .می‌کند
(H_norm) آنتروپی نرمال‌شده	پراکندگی احتمال‌ها بین گزینه‌ها؛ مقدار بالاتر معمولاً یعنی احتمال‌ها پخش‌ترند .برای مقایسه .نرمال می‌شود (log(K تعداد گزینه‌های متفاوت، بر
(Margin) فاصله دو گزینه برتر	اختلاف احتمال گزینه اول و دوم؛ فاصله کم یعنی دو .گزینه از نظر مدل به هم نزدیک‌اند
(A_sample) توافق پاسخ‌های تکراری	سهم نمونه‌گیری‌های تکراری که همان پاسخ غالب را تولید می‌کنند؛ ثبات یا ناپایداری پاسخ را خلاصه .می‌کند
(S_order) پایداری نسبت به ترتیب گزینه‌ها	سهم تغییرهای کنترل‌شده در ترتیب گزینه‌ها که .پاسخ معنایی انتخاب‌شده را تغییر نمی‌دهند
(L_question) طول سؤال	تعداد توکن‌های متن سؤال؛ ویژگی کمکی برای بررسی اینکه طول ورودی با خطا یا عدم‌قطعیت .ارتباط دارد یا نه
(L_option) میانگین طول گزینه‌ها	میانگین تعداد توکن‌های گزینه‌ها؛ برای کنترل .تفاوت طول گزینه‌ها در سؤال‌های مختلف
(C_domain) حوزه یا دسته موضوعی	یا ،MMLU در subject برچسب دسته‌ای مانند حوزه دیتاست؛ در صورت استفاده، به‌عنوان ویژگی .دسته‌ای کدگذاری می‌شود

منابع ۳۰

- Kadavath, S., et al. (2022). Language Models (Mostly) Know What They Know. https://www.anthropic.com/research/language-models-mostly-know-what-they-know
- Manakul, P., Liusie, A., & Gales, M. (2023). SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models. EMNLP 2023. https://aclanthology.org/2023.emnlp-main.557/
- Xiong, M., et al. (2024). Can LLMs Express Their Uncertainty? An Empirical Evaluation of Confidence Elicitation in LLMs. ICLR 2024. https://proceedings.iclr.cc/paper_files/paper/2024/hash/6733cf15e10e2cd1d59af033c3bb8507-Abstract-Conference.html
- Farquhar, S., et al. (2024). Detecting Hallucinations in Large Language Models Using Semantic Entropy. Nature. https://www.nature.com/articles/s41586-024-07421-0
- Chen, J., & Mueller, J. (2024). Quantifying Uncertainty in Answers from Any Language Model and Enhancing Their Trustworthiness. ACL 2024. https://aclanthology.org/2024.acl-long.283/
- Huang, Y., et al. (2024). Uncertainty in Language Models: Assessment through Rank-Calibration. EMNLP 2024. https://aclanthology.org/2024.emnlp-main.18/
- Ye, F., et al. (2024). Benchmarking LLMs via Uncertainty Quantification. NeurIPS 2024. https://papers.nips.cc/paper_files/paper/2024/hash/1bdcb065d40203a00bd39831153338bb-Abstract-Datasets_and_Benchmarks_Track.html
- Geng, J., et al. (2025). Towards Harmonized Uncertainty Estimation for Large Language Models. ACL 2025. https://aclanthology.org/2025.acl-long.1118/
- Chen, et al. (2026). Uncertainty Quantification of Large Language Models through Multiple Uncertainty Sources. Findings of ACL 2026. https://aclanthology.org/2026.findings-acl.535/
- Geng, J., et al. (2024). A Survey of Confidence Estimation and Calibration in Large Language Models. NAACL 2024. https://aclanthology.org/2024.naacl-long.366/